

8. SEGMENTAÇÃO

- Tarefa não trivial
- Facilitada por condições ambientes controladas
- Sob condições não controladas, facilitada pelo uso de sensores específicos

8.1. FUNDAMENTOS

- Derivada de ordem 1
 - Expandindo-se a função $f(x+\Delta x)$ em Série de Taylor sobre x ;
 - Assumindo-se $\Delta x=1$
 - Mantendo-se apenas os termos lineares

$$\frac{\partial f}{\partial x} = f'(x) = f(x+1) - f(x)$$

- Derivada de ordem 2

$$\begin{aligned}\frac{\partial^2 f}{\partial x^2} &= \frac{\partial f'(x)}{\partial x} = f'(x+1) - f'(x) \\ &= f(x+2) - f(x+1) - f(x+1) + f(x) \\ &= f(x+2) - 2f(x+1) + f(x)\end{aligned}$$

- Expansão sobre o ponto $(x+1)$. Portanto...

$$\frac{\partial^2 f}{\partial x^2} = f''(x) = f(x+1) + f(x-1) - 2f(x)$$

- Mais agressiva que a derivada de ordem 1...

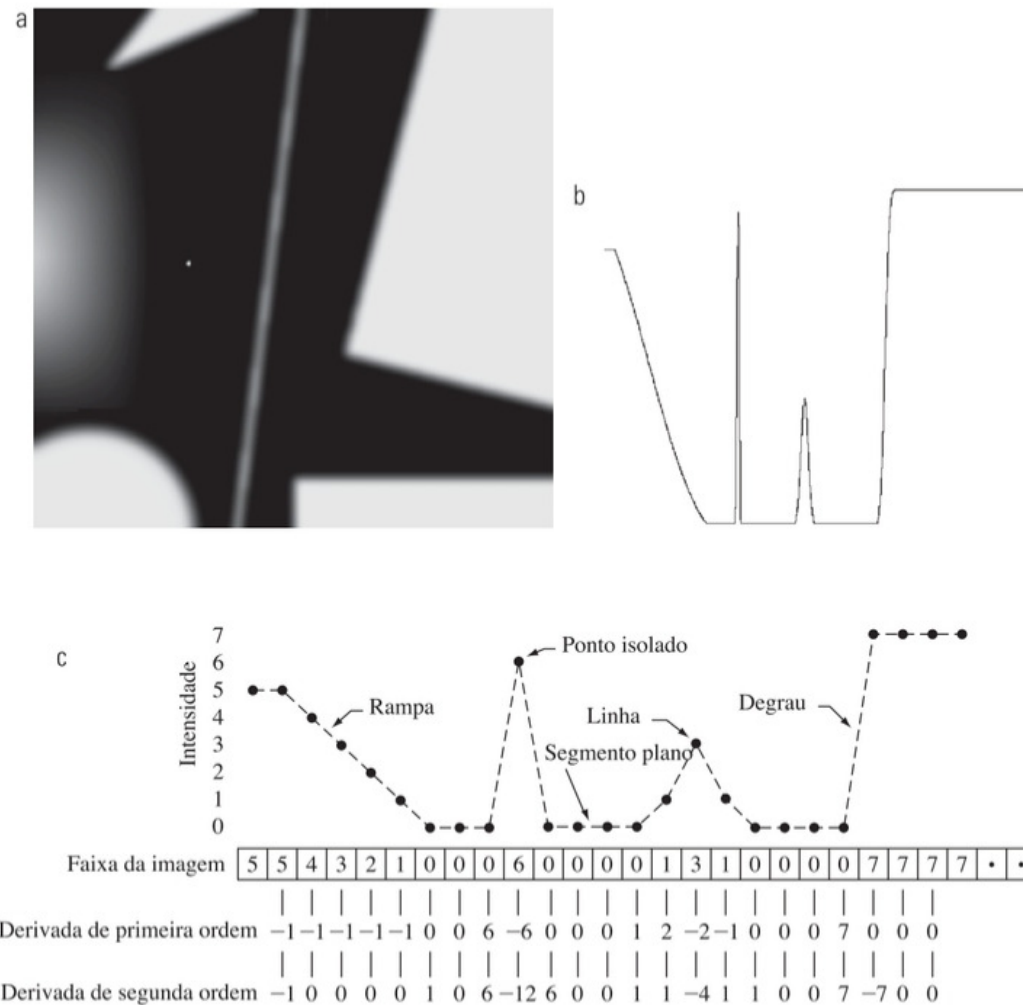


Figura 10.2 (a) Imagem (b) Perfil de intensidade horizontal no centro da imagem, incluindo o ponto de ruído isolado, (c) Perfil simplificado (os pontos estão unidos com traços para facilitar o entendimento). A faixa da imagem corresponde ao perfil de intensidade, e os números nas caixas são os valores de intensidade dos pontos mostrados no perfil. As derivadas foram obtidas utilizando as equações 10.2-1 e 10.2-2.

- Gradiente

$$\nabla f = \text{grad}(f) = \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$$

em que

$$g_x = \frac{\partial f(x, y)}{\partial x} = f(x+1, y) - f(x, y) \quad ; \quad g_y = \frac{\partial f(x, y)}{\partial y} = f(x, y+1) - f(x, y)$$

- Aponta na direção do máximo crescimento da função
- Magnitude do vetor

$$M(x, y) = \text{mag}(\nabla f) = \sqrt{g_x^2 + g_y^2}$$

$$\text{ou } M(x, y) = \text{mag}(\nabla f) \simeq |g_x| + |g_y|$$

▪ Implementação por convolução

-1
1

-1	1
----	---

- Roberts: bordas diagonais

- Prewitt e Sobel: ênfase em

direções específicas

0	1	1
-1	0	1
-1	-1	0

c

-1	-1	0
-1	0	1
0	1	1

Prewitt

d

0	1	2
-1	0	1
-2	-1	0

Sobel

-2	-1	0
-1	0	1
0	1	2

-1	0	0	-1
0	1	1	0

d

Roberts

e

-1	-1	-1
0	0	0
1	1	1

-1	0	1
-1	0	1
-1	0	1

f

Prewitt

g

-1	-2	-1
0	0	0
1	2	1

-1	0	1
-2	0	2
-1	0	1

Sobel

- Direção do vetor

$$\alpha(x, y) = \text{tg}^{-1} \left(\frac{g_y}{g_x} \right)$$

- Direção da borda é perpendicular à direção do gradiente

- Laplaciano

$$\begin{aligned} \nabla^2 f(x, y) &= \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \\ &= f(x+1, y) + f(x-1, y) + f(x, y+1) \\ &\quad + f(x, y-1) - 4f(x, y) \end{aligned}$$

- Derivadas e Laplaciano implementados por convolução

1	1	1
1	-8	1
1	1	1

Isotrópico
(invariante à rotação)

-1	-1	-1
2	2	2
-1	-1	-1

horizontal

2	-1	-1
-1	2	-1
-1	-1	2

+45°


-1	2	-1
-1	2	-1
-1	2	-1


Vertical

-1	-1	2
-1	2	-1
2	-1	-1

-45°

- Comportamento frente a ruído





- Transformada de Hough

- $y_i = ax_i + b \Rightarrow b = -ax_i + y_i$ (plano ab ; espaço de parâmetros)
- $y_i = ax_i + b \Rightarrow$ muitas/infinitas retas passam por (x_i, y_i)
- $b = -ax_i + y_i \Rightarrow$ uma única reta passa por (a', b')




Figura 10.31 (a) Plano xy . (b) Espaço de parâmetros.

- Problema $\Rightarrow a \rightarrow \infty$ quando a inclinação da reta é vertical
- Solução: equação normal da reta (coordenadas polares)

$$x \cos \theta + y \sin \theta = \rho$$




Figura 10.32 (a) (ρ, θ) Parametrização da reta no plano xy . (b) Curvas senoidais no plano $\rho\theta$; o ponto de interseção (ρ', θ') corresponde à reta que passa pelos pontos (x_i, y_i) e (x_j, y_j) no plano xy . (c) Divisão do plano $\rho\theta$ em células acumuladoras.

8.2. LIMIAÇÃO

- Classificações
 - Limiarização global
 - Limiarização variável, local, regional, dinâmica, adaptativa, etc.




Figura 10.35 Histogramas de intensidade que podem ser divididos (a) por um limiar único e (b) por limiares duplos.

(ex: objetos claros sobre fundo escuro)

- Influência do ruído

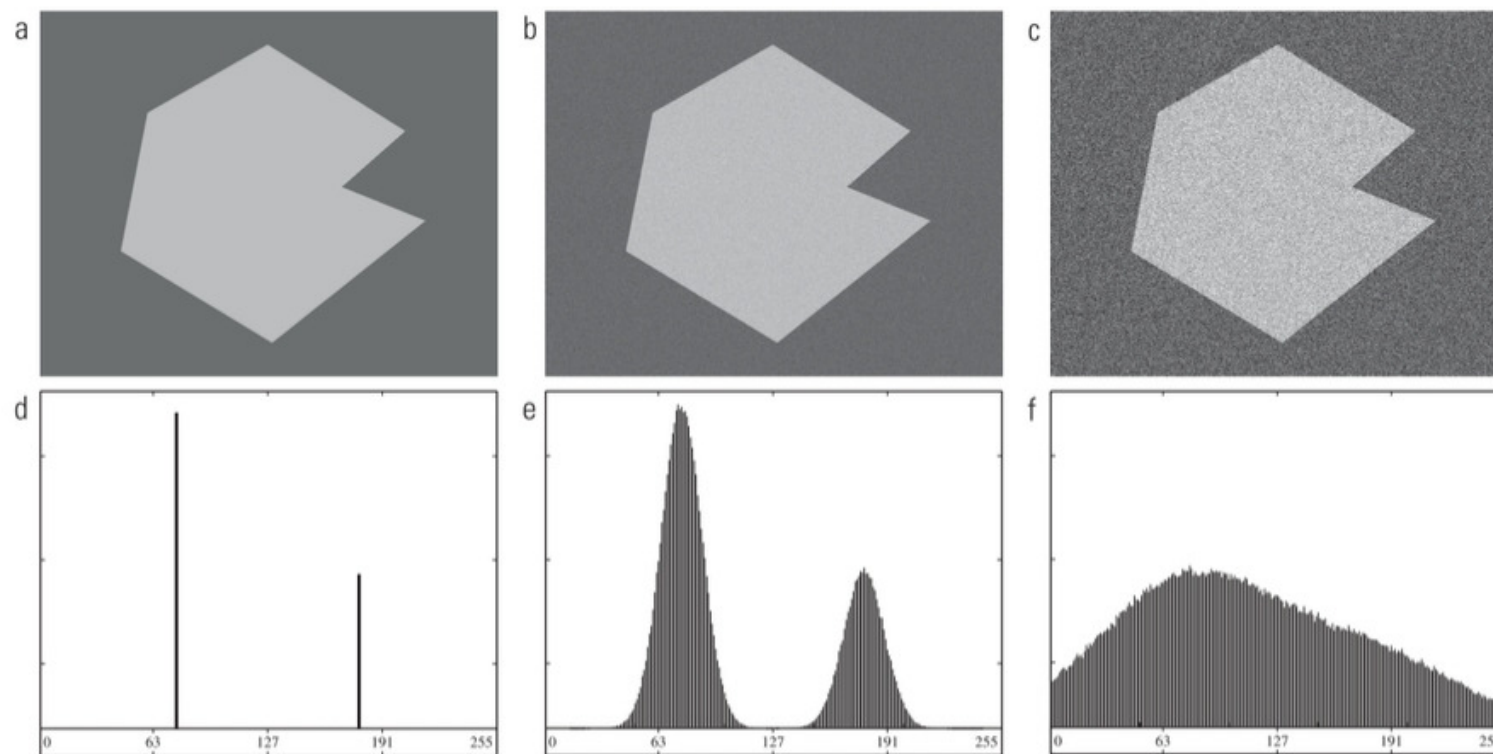


Figura 10.36 (a) Imagem de 8 bits livre de ruído. (b) Imagem com ruído gaussiano aditivo de média 0 e desvio padrão de 10 níveis de intensidade. (c) Imagem com ruído gaussiano aditivo de média 0 e desvio padrão de 50 níveis de intensidade. (d) a (f) Histogramas correspondentes.

- Influência da iluminação

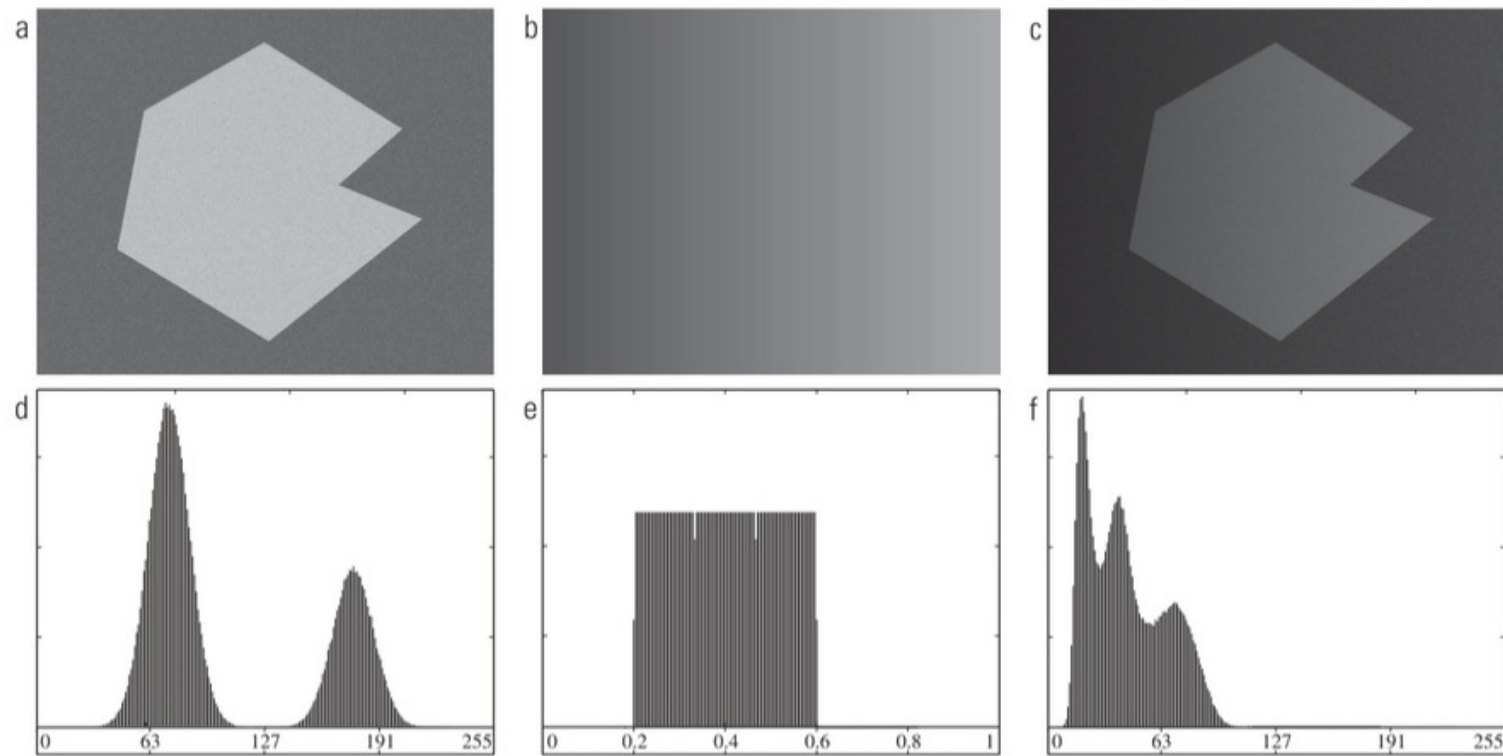


Figura 10.37 (a) Imagem ruidosa (b) Rampa de intensidade no intervalo $[0,2, 0,6]$. (c) Produto de (a) e (b). (d) a (f) Histogramas correspondentes.

- Definição Automática do Limiar
 - Limiarização Global Simples
 1. Selecionar uma estimativa do limiar global T (por exemplo, valor da intensidade média da imagem)
 2. Segmentar a imagem usando T e formando dois grupos de pixels, G_1 e G_2
 3. Calcular os valores m_1 e m_2 das intensidades média dos grupos G_1 e G_2
 4. Calcular um novo limiar $T = \frac{1}{2}(m_1 + m_2)$
 5. Repetir as etapas 2 a 4 até que a variação de T em iterações sucessivas seja menor que um valor predefinido ΔT
-

- Limiarização Global Ótima pelo Método de Otsu
 - Maximiza a variância entre as classes
 - Trabalha diretamente sobre o histograma da imagem (baixo custo computacional)
 - Níveis de cinza de uma imagem $M \times N \Rightarrow [0, 1, 2, \dots, L-1]$
 - Número de pixels com intensidade $i \Rightarrow n_i$
 - $MN = n_0 + n_1 + n_2 + \dots + n_{L-1}$
 - O histograma normalizado tem componentes $p_i = n_i / NM$ e $\sum_{i=0}^{L-1} p_i = 1$
 - Limiar $T(k) = k$ separa a imagem em duas classes C_1 e C_2
-

- A probabilidade de um pixel ser atribuído a C_1 , ou seja, a probabilidade de ocorrência da classe C_1 é $P_1(k) = \sum_{i=0}^k p_i$

- A intensidade média dos pixels da classe C_1 pode ser definido como

$$m_1(k) = \sum_{i=0}^k iP(i|C_1)$$

- Da regra de Bayes

$$P(A|B) = P(B|A)P(A)/P(B),$$

segue que

$$m_1(k) = \sum_{i=0}^k iP(C_1|i)P(i)/P(C_1).$$

Como $0 \leq i \leq k$, $P(C_1|i)=1$. Note-se também que $P(i)=p_i$ e $P(C_1)=P_1(k)$, portanto

$$m_1(k) = \frac{1}{P_1(k)} \sum_{i=0}^k i p_i$$

- Figura de mérito para a qualidade do limiar k :

$$\eta(k) = \frac{\sigma_B^2(k)}{\sigma_G^2}$$

- $\sigma_G^2 = \sum_{i=0}^{L-1} (i - m_G)^2 p_i \Rightarrow$ variância global

em que $m_G = \sum_{i=0}^{L-1} i p_i$

- $\sigma_B^2(k) = (m_1 - m_G)^2 P_1(k) + (m_2 - m_G)^2 P_2(k) \Rightarrow$ variância entre classes
-

- É possível mostrar que $\sigma_B^2(k) = P_1(k)P_2(k)(m_1 - m_2)^2$
- Quanto mais distantes as médias, maior $\sigma_B^2(k) \Rightarrow$ variância entre as classes é uma medida de separabilidade
- $\sigma_B^2(k)$ pode ser escrito como $\sigma_B^2(k) = \frac{[m_G P_1(k) - m(k)]^2}{P_1(k)[1 - P_1(k)]}$

em que $m(k) = \sum_{i=0}^k ip_i$, $m_G = \sum_{i=0}^{L-1} ip_i$ e $P_1(k) = \sum_{i=0}^k p_i$

- Mais eficiente computacionalmente
- Como σ_G^2 é constante, maximizar $\eta(k)$ equivale a maximizar $\sigma_B^2(k)$

- FINALMENTE: determinar $\sigma_B^2(k)$ para todos os valores de k entre 0 e $L-1$ e escolher o k que maximiza $\sigma_B^2(k)$. Obs: pode haver mais de um k que maximiza $\sigma_B^2(k)$.




Figura 10.39 (a) Imagem original. (b) Histograma (os picos elevados foram cortados para realçar os detalhes nos valores mais baixos). (c) Resultado da segmentação utilizando o algoritmo global básico da Seção 10.3.2. (d) Resultado obtido pelo método de Otsu. (Imagem original: cortesia do Professor Daniel A. Hammer, da Universidade da of Pennsylvania.)